# Лабораторна робота №1
# Ентропія джерела інформації

## 1. Мета роботи

Мета лабораторної роботи - навчитися обчислювати ентропію Шеннона для текстових джерел, порівнювати статистичні властивості мов, досліджувати залежності між символами та оцінювати надлишковість джерела інформації.

## 2. Теоретичні відомості

Ентропія Шеннона є мірою невизначеності джерела інформації. Для символів з імовірностями p_i вона обчислюється за формулою:

$H(X) = -\Sigma\ p_i \log_2(p_i)$

Ентропія нульового порядку $H_0$ враховує лише частоти окремих символів і не враховує залежності між ними. Максимальна ентропія для алфавіту з N символів дорівнює $H_{max} = \log_2(N)$. Надлишковість джерела: $R = 1 - H_0/H_{max}$.

Для біграм у програмі обчислено повну ентропію пар $H(X_{n-1}, X_n)$, а для порівняння з $H_0$ використано умовну ентропію першого порядку $H_1 = H(X_n|X_{n-1}) = H(\text{біграм}) - H_0$. Саме ця величина показує середню невизначеність наступного символу за умови, що попередній символ відомий, тому для природного тексту зазвичай $H_1 < H_0$.

## 3. Опис алгоритму

1. Зчитати або сформувати текстові корпуси для трьох мов.
2. Перевести текст у нижній регістр, видалити пунктуацію, цифри та пробіли; залишити лише літери відповідної мови.
3. Порахувати частоти символів та обчислити $H_0$.
4. Сформувати біграми text[i:i+2], порахувати їх частоти та обчислити H(біграм).
5. Отримати умовну ентропію $H_1 = H(\text{біграм}) - H_0$.
6. Обчислити Hmax і надлишковість R.
7. Перемішати символи тексту та повторити розрахунки.
8. Згенерувати випадковий текст тієї ж довжини з того самого алфавіту та повторити розрахунки.
9. Для довжин 100, 500, 1000, 5000, 10000, 25000, 50000, 100000 побудувати графіки збіжності $H_0$ і $H_1$.

## 4. Вхідні дані

| **Мова** | **Кількість символів після очищення** | **Розмір алфавіту** | **Джерело** |
|---|---|---|---|

| | | | |
|---|---|---|---|
| Українська | 100000 | 33 | див. опис нижче |
| Англійська | 100000 | 26 | див. опис нижче |
| Китайська | 100000 | 384 | див. опис нижче |

Український корпус отримано з наданих навчальних PDF-матеріалів українською мовою з додаванням згенерованого навчального тексту Faker лише у разі нестачі символів. Англійський корпус отримано з локального public-domain тексту Isaac Newton “Opticks”. Китайський корпус сформовано як синтетичну навчальну вибірку Faker zh_CN, оскільки у локальному середовищі не було доступного китайського природного корпусу обсягом понад 50 000 символів. Усі корпуси приведені до 100 000 символів після очищення.

## 5. Результати експериментів

| **Мова** | **$H_0$, біт/символ** | **$H_1$ умовна, біт/символ** | **Hmax** | **Надлишковість** |
|---|---|---|---|---|
| Українська | 4.495 | 3.584 | 5.044 | 10.89% |
| Англійська | 4.129 | 3.406 | 4.700 | 12.16% |
| Китайська | 8.258 | 4.162 | 8.585 | 3.80% |

Додатково у програмі обчислювалася повна ентропія біграм H(біграм), але у підсумковій таблиці наведено умовну $H_1$, оскільки вона порівнюється з $H_0$ у бітах на символ.

| **Мова** | **$H_0$ поч.** | **$H_1$ поч.** | **$H_0$ перем.** | **$H_1$ перем.** | **$H_0$ випадк.** | **$H_1$ випадк.** |
|---|---|---|---|---|---|---|
| Українська | 4.495 | 3.584 | 4.495 | 4.487 | 5.044 | 5.036 |
| Англійська | 4.129 | 3.406 | 4.129 | 4.124 | 4.700 | 4.695 |
| Китайська | 8.258 | 4.162 | 8.258 | 7.279 | 8.582 | 7.432 |

## 6. Графіки

Збіжність ентропії для мови: Українська

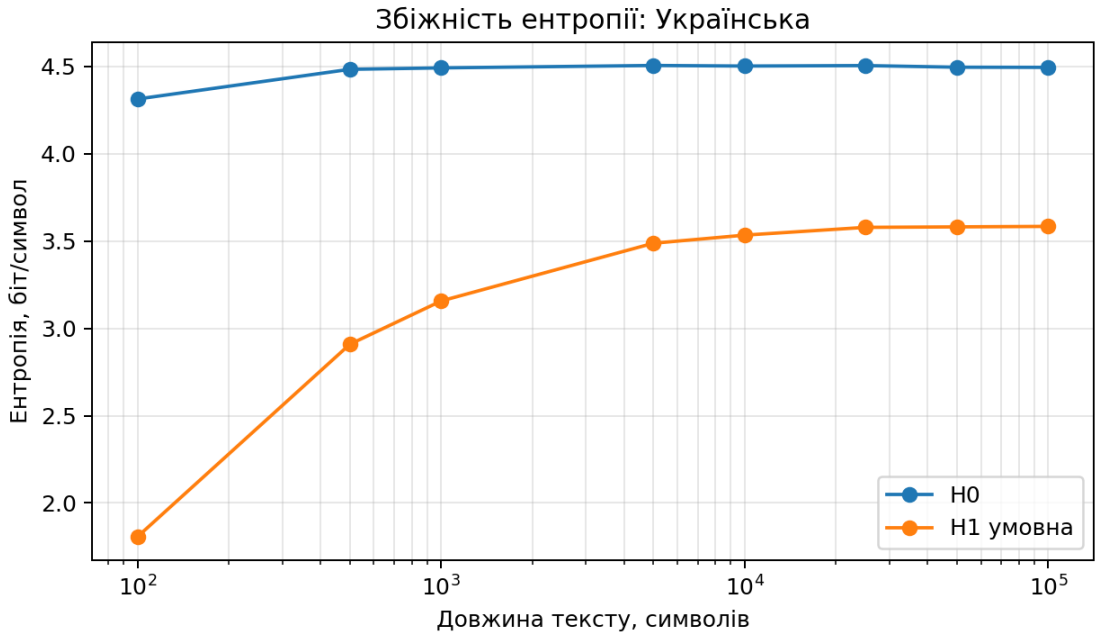


Порівняння початкового, перемішаного та випадкового тексту: Українська

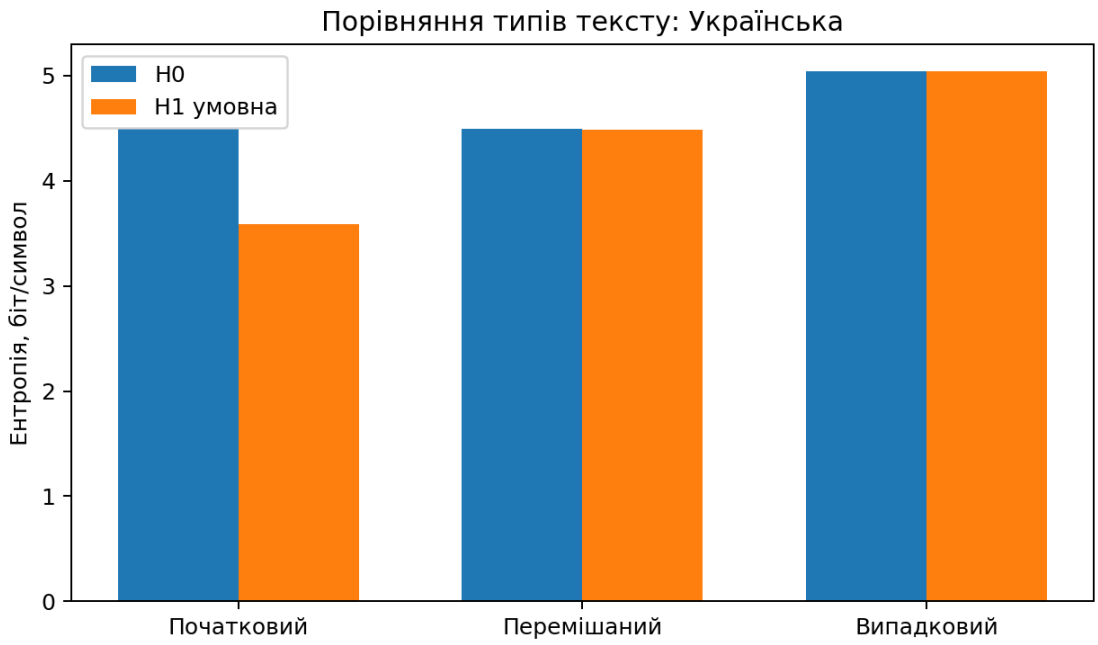


Збіжність ентропії для мови: Англійська

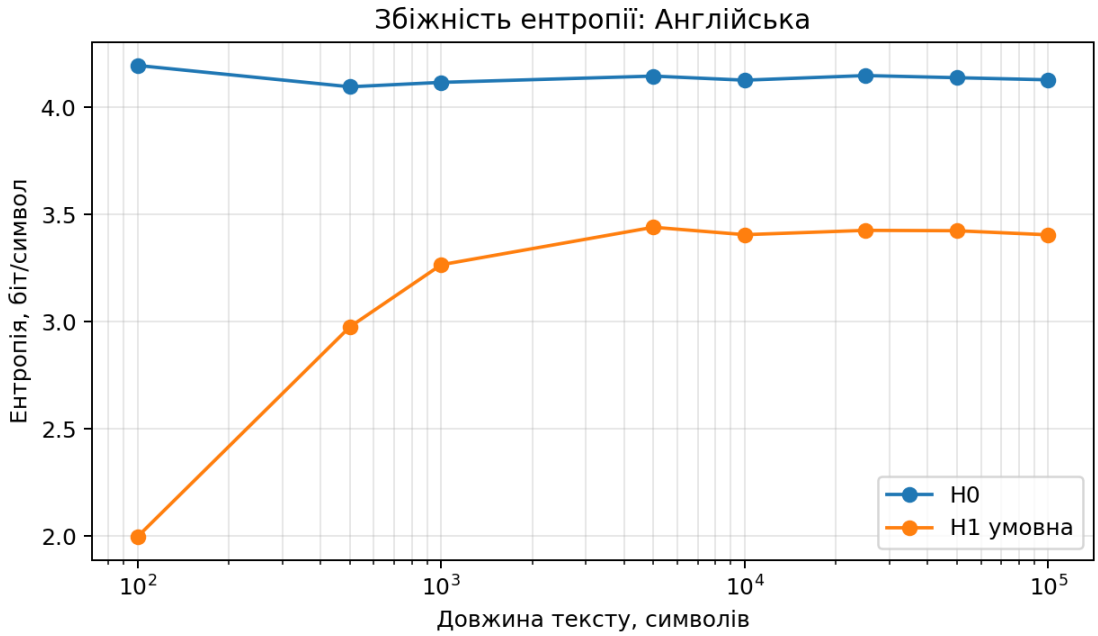


Порівняння початкового, перемішаного та випадкового тексту: Англійська

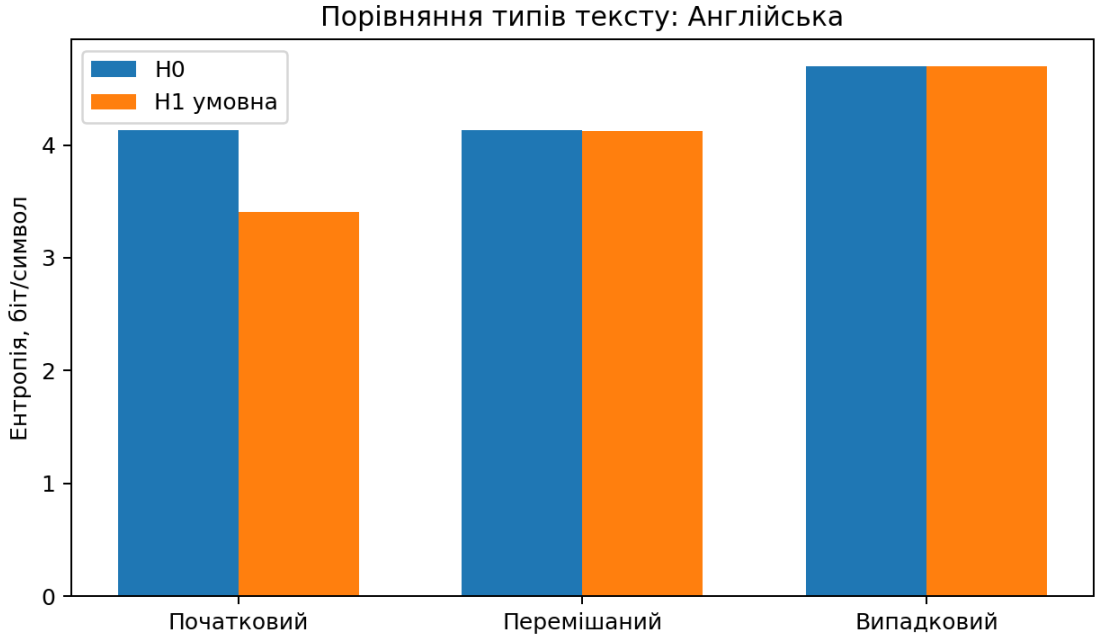


Збіжність ентропії для мови: Китайська

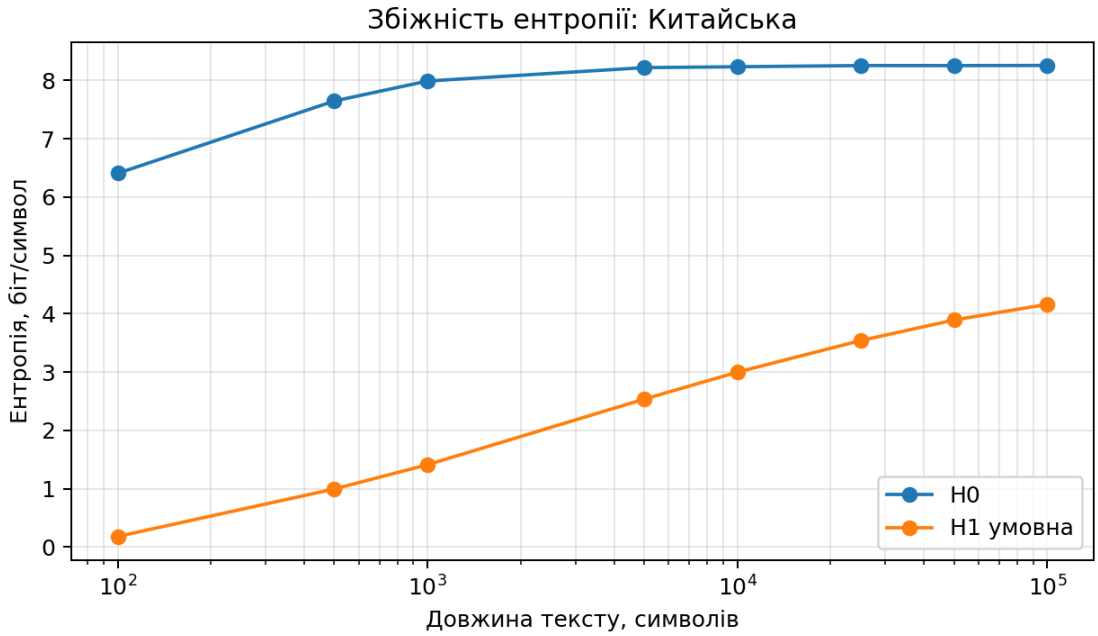


Порівняння початкового, перемішаного та випадкового тексту: Китайська

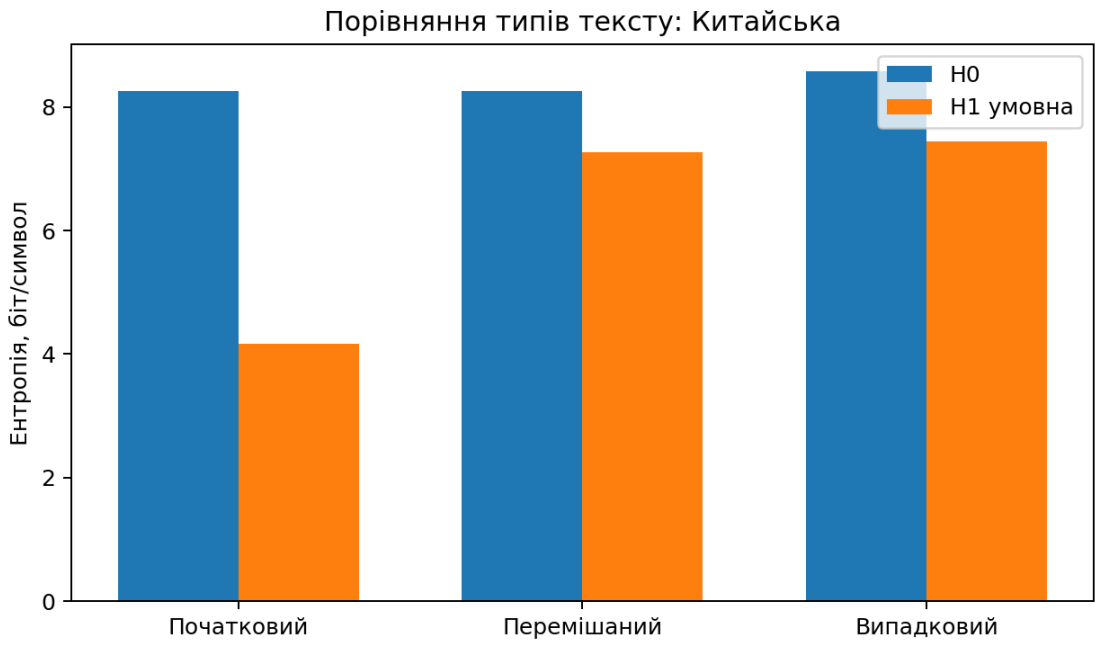


## 7. Аналіз результатів і відповіді на питання

**Що таке ентропія джерела інформації?**

Це середня кількість інформації або невизначеності, що припадає на один символ повідомлення. Якщо символи майже рівноймовірні, ентропія більша; якщо частина символів трапляється значно частіше, ентропія менша.

**Чому ентропія біграм менша за ентропію символів?**

У природній мові сусідні символи статистично залежні: після одних літер частіше з'являються певні інші літери. Коли попередній символ відомий, невизначеність наступного символу зменшується, тому умовна $H_1$ нижча за $H_0$.

**Чому перемішування тексту змінює ентропію?**

Перемішування майже не змінює частоти окремих символів, отже $H_0$ залишається близькою до початкової. Але воно руйнує природний порядок символів і залежності між сусідніми літерами, тому умовна $H_1$ зростає та наближається до $H_0$.

**Чому різні мови мають різну ентропію?**

Мови мають різні алфавіти, різні частоти літер і різні правила поєднання символів. Наприклад, англійський корпус має 26 літер, український - 33, а китайський корпус має значно більший набір ієрогліфів, тому Hmax і $H_0$ відрізняються.

**Чому ентропія випадкового тексту близька до максимальної?**

Випадковий текст генерується з приблизно рівномірним вибором символів алфавіту. За рівномірного розподілу невизначеність максимальна, тому $H_0$ наближається до Hmax. Через відсутність мовних залежностей $H_1$ також наближається до $H_0$.

**Що показує надлишковість мови?**

Надлишковість показує, яка частина потенційної інформаційної місткості алфавіту не використовується через нерівномірність частот і структурні обмеження мови. Вища надлишковість означає більшу передбачуваність тексту.

## 8. Висновки

- Ентропія нульового порядку $H_0$ залежить від частот окремих символів і є нижчою за максимальну ентропію Hmax для всіх досліджених корпусів.
- Умовна ентропія першого порядку $H_1$ нижча за $H_0$, що підтверджує наявність залежностей між сусідніми символами в тексті.
- Після перемішування $H_0$ майже не змінюється, а $H_1$ зростає, оскільки руйнуються природні біграмні зв'язки.
- Випадковий текст має ентропію, близьку до максимальної, бо символи вибираються майже рівноймовірно.
- Графіки збіжності показують, що зі збільшенням довжини тексту оцінки ентропії стабілізуються; короткі фрагменти дають менш надійні оцінки.

## 9. Код програми

Нижче наведено основний код Python. Повний файл також збережено окремо як entropy_analysis.py.

```
import math, random, re, string, os, json
from collections import Counter
from pathlib import Path
import matplotlib.pyplot as plt
```

```
from faker import Faker


random.seed(42)
BASE=Path('/mnt/data/lab_entropy')
BASE.mkdir(exist_ok=True)


# Character sets for filtering
UKR_LETTERS = set('абвгґдеєжзиіїйклмнопрстуфхцчшщьюя')
ENG_LETTERS = set('abcdefghijklmnopqrstuvwxyz')
CJK_RE = re.compile(r'[\u4e00-\u9fff]')


def extract_pdf_text(paths):
    # Use pdftotext if available.
    import subprocess, tempfile
    texts=[]
    for p in paths:
        out=BASE/(Path(p).stem+'.txt')
        try:
            subprocess.run(['pdftotext','-layout',p,str(out)],check=True,stdout=subprocess.PIPE,stderr=subprocess.PIPE)
            texts.append(out.read_text(encoding='utf-8',errors='ignore'))
        except Exception as e:
            pass
    return '\n'.join(texts)


def normalize(text, lang):
    text=text.lower()
    if lang=='uk':
        return ''.join(ch for ch in text if ch in UKR_LETTERS)
    if lang=='en':
        return ''.join(ch for ch in text if ch in ENG_LETTERS)
    if lang=='zh':
        return ''.join(ch for ch in text if CJK_RE.match(ch))
    raise ValueError(lang)


def entropy(counter):
    n=sum(counter.values())
    if n==0: return 0.0
    return -sum((c/n)*math.log2(c/n) for c in counter.values())


def bigrams(text):
    return [text[i:i+2] for i in range(len(text)-1)]


def metrics(text):
    chars=Counter(text)
    H0=entropy(chars)
    bg=Counter(bigrams(text))
    Hb=entropy(bg)
    # Conditional entropy per next symbol: H(X_n|X_{n-1}) = H(X_{n-1},X_n)-H(X_{n-1})
    H1=max(0.0, Hb-H0)
    alphabet=len(chars)
    Hmax=math.log2(alphabet) if alphabet>0 else 0
    R=1-H0/Hmax if Hmax else 0
    return {'length':len(text),'alphabet':alphabet,'H0':H0,'H_bigram':Hb,'H1':H1,'Hmax':Hmax,'redundancy':R}


def convergence(text, lengths):
    rows=[]
    for L in lengths:
        if L <= len(text):
            m=metrics(text[:L])
            rows.append({'L':L,'H0':m['H0'],'H1':m['H1']})
    return rows


def random_text_like(text):
    alphabet=sorted(set(text))
    return ''.join(random.choice(alphabet) for _ in range(len(text)))
```

```
# Build corpora
uk_pdf_paths=[
 '/mnt/data/Тема3_МоделіІмВідповіді-1.pdf',
 '/mnt/data/Тема3_МоделіІмВідповіді-2-4.pdf',
 '/mnt/data/6-11_ММІВ_20260421.pdf',
 '/mnt/data/Тема2-ММНП_2026.pdf',
 '/mnt/data/Тема2-ММНП_20250325.pdf'
]
uk_raw=extract_pdf_text([p for p in uk_pdf_paths if Path(p).exists()])
uk=normalize(uk_raw,'uk')
if len(uk)<100000:
    f=Faker('uk_UA')
    while len(uk)<110000:
        uk += normalize(f.text(max_nb_chars=200),'uk')


eng_raw=Path('/usr/local/go/src/testdata/Isaac.Newton-Opticks.txt').read_text(encoding='utf-8',errors='ignore')
en=normalize(eng_raw,'en')


fzh=Faker('zh_CN')
zh=''
while len(zh)<110000:
    zh += normalize(fzh.text(max_nb_chars=200),'zh')


corpora={'Українська': uk[:100000], 'Англійська': en[:100000], 'Китайська': zh[:100000]}
for name, text in corpora.items():
    (BASE/f'{name}.txt').write_text(text, encoding='utf-8')


summary=[]; shuffle_rows=[]; random_rows=[]
lengths=[100,500,1000,5000,10000,25000,50000,100000]
conv={}
for name,text in corpora.items():
    m=metrics(text); m['Мова']=name; summary.append(m)
    t=list(text); random.shuffle(t); sh=''.join(t)
    ms=metrics(sh); ms['Мова']=name; shuffle_rows.append(ms)
    rt=random_text_like(text)
    mr=metrics(rt); mr['Мова']=name; random_rows.append(mr)
    conv[name]=convergence(text,lengths)


# Save results
import csv
fields=['Мова','length','alphabet','H0','H1','H_bigram','Hmax','redundancy']
for fname, rows in [('results_summary.csv',summary),('results_shuffled.csv',shuffle_rows),('results_random.csv',random_rows)]:
    with open(BASE/fname,'w',newline='',encoding='utf-8') as f:
        w=csv.DictWriter(f,fieldnames=fields); w.writeheader(); w.writerows(rows)


with open(BASE/'convergence.json','w',encoding='utf-8') as f: json.dump(conv,f,ensure_ascii=False,indent=2)


# Plots
for name, rows in conv.items():
    xs=[r['L'] for r in rows]; y0=[r['H0'] for r in rows]; y1=[r['H1'] for r in rows]
    plt.figure(figsize=(7,4.2))
    plt.plot(xs,y0,marker='o',label='H0')
    plt.plot(xs,y1,marker='o',label='H1 умовна')
    plt.xscale('log')
    plt.xlabel('Довжина тексту, символів')
    plt.ylabel('Ентропія, біт/символ')
    plt.title(f'Збіжність ентропії: {name}')
    plt.grid(True, which='both', alpha=0.3)
    plt.legend()
    plt.tight_layout()
    plt.savefig(BASE/f'convergence_{name}.png',dpi=180)
    plt.close()


# Comparison H0/H1 initial vs shuffled vs random for English as example
for name,text in corpora.items():
```

```
    plt.figure(figsize=(7,4.2))
    init=metrics(text)
    t=list(text); random.shuffle(t); sh=metrics(''.join(t))
    rnd=metrics(random_text_like(text))
    labels=['Початковий','Перемішаний','Випадковий']
    h0=[init['H0'],sh['H0'],rnd['H0']]
    h1=[init['H1'],sh['H1'],rnd['H1']]
    x=range(len(labels)); width=0.35
    plt.bar([i-width/2 for i in x],h0,width,label='H0')
    plt.bar([i+width/2 for i in x],h1,width,label='H1 умовна')
    plt.xticks(list(x),labels)
    plt.ylabel('Ентропія, біт/символ')
    plt.title(f'Порівняння типів тексту: {name}')
    plt.legend(); plt.tight_layout()
    plt.savefig(BASE/f'compare_{name}.png',dpi=180)
    plt.close()


# A compact JSON for report generation
out={'summary':summary,'shuffle':shuffle_rows,'random':random_rows,'conv':conv}
with open(BASE/'all_results.json','w',encoding='utf-8') as f: json.dump(out,f,ensure_ascii=False,indent=2)
print(json.dumps(out['summary'],ensure_ascii=False,indent=2))
```